



# Kategorielle Daten

## Phase 3 Studie: Wirksamer als Placebo ?

	Medikament	Placebo	Total
Geheilt	15	9	24
Nicht geheilt	10	11	21
Total	25	20	45

Grundfrage: Sind “Heilung” und “Medikamentengabe” unabhängig ?


# Statistische Tests für Tabellen

- **Fisher's Exact Test:** 2 x 2 Tabellen  
Verteilung der Teststatistik **exakt**
- **Chi-Quadrat Test:** m x n Tabellen  
Verteilung der Teststatistik **asymptotisch** bekannt
- **Logistische Regression:** 2 x m Tabellen;  
auch Mix aus mehreren kontinuierlichen und kategoriellen erklärenden Variablen möglich  
Verteilung der Teststatistik **asymptotisch** bekannt  
***Multiple oder einfache ?***


# Wdh: Hypergeometrische Verteilung

- Situation: Urne mit  $N$  Kugeln;  $m$  sind markiert; ziehen  $n$  Kugeln ohne Zurücklegen; wie viele markierte Kugeln?
- ZV  $X$ : Anzahl markierter gezogener Kugeln
- $X \sim \text{Hyper}(N, n, m)$   
 “ $X$  ist hypergeometrisch verteilt mit Paramtern  $N$ ,  $n$  und  $m$ ”
- $P(X = x) = \frac{\binom{m}{x} \binom{N-m}{n-x}}{\binom{N}{n}}$  ← ‘günstig’,  $x \in \{0, 1, \dots, \min(n, m)\}$   
 ← ‘möglich’
- $E(X) = \frac{n \cdot m}{N}$ ,  $\text{Var}(X)$  kompliziert; siehe z.B. Wikipedia

Hyper(15,10,10)



Hyper(15,10,10)



## Bsp: Phase 3 Studie – Wirksamer als Placebo?

- Doppel-blinde, randomisierte Studie

Gezogene und markierte Bälle

	Medikament	Placebo	Total
Geheilt	15	9	24
Nicht geheilt	10	11	21
Total	25	20	45

Markierte Bälle (m)

Gezogene Bälle (n)

Bälle in Urne (N)

- Falls Medikament keine Wirkung hat: Es gibt 24 Personen, bei denen unabhängig von der Gruppenzuteilung fest steht, dass sie gesund werden

➔ **Urnenmodell**

# Fisher's Exact Test: Spalten und Zeilen unabhängig ?

	Medikament	Placebo	Total
Geheilt	15	9	24
Nicht geheilt	10	11	21
Total	25	20	45

- ZV X: Anzahl geheilter Patienten in Medikamenten-Gruppe
- Falls Medikament keine Wirkung hat:

$$X \sim \text{Hyper}(N = 45, m = 24, n = 25)$$

- Ist es dann plausibel in der Medikamenten-Gruppe 15 oder mehr geheilte Patienten zu beobachten?
- $P(X \geq 15) = 1 - P(X \leq 14) = 1 - 0.76 = 0.24$  P-Wert

R: `phyper(14,24,21,25)`

- Falls das Medikament nicht wirkt, ist es durchaus plausibel 15 oder mehr geheilte Patienten in der Medikamentengruppe zu beobachten

## Wdh: Odds und Odds-Ratio

	Medikament	Placebo	Total
Geheilt	15	9	24
Nicht geheilt	10	11	21
Total	25	20	45

Alternative Beschreibung von Wahrscheinlichkeiten

- $\text{Odds}(A) = P(A) / (1 - P(A))$
- $P(A) = \text{Odds}(A) / (1 + \text{Odds}(A))$
- $\text{Log-Odds}(A) = \log(\text{Odds}(A))$

Wirksamkeit von Medikament  
kann mit Odds-ratio  
ausgedrückt werden

$$\text{Odds}(\text{Geheilt}) = (24/45) / (21/45) = 24/21 = 1.14$$

$$\text{Odds}(\text{Geheilt mit Medi}) = (15/25) / (10/25) = 15/10 = 1.5$$

$$\text{Odds}(\text{Geheilt ohne Medi}) = (9/20) / (11/20) = 9/11 = 0.82$$

**Odds-ratio:**  $\text{Odds}(\text{Geheilt mit Medi}) / \text{Odds}(\text{Geheilt ohne Medi}) = 1.5 / 0.82 = 1.83$



# Fisher's Exact Test in R

```
> m <- matrix(c(15,10,9,11),2,2)
> m
      [,1] [,2]
[1,]   15   9
[2,]   10  11
> fisher.test(m, alternative = "greater")
```

Einseitige Alternative:  
Grössere Macht ein wirksames  
Medikament zu finden

**Blind für unwirksame Medikamente**

Fisher's Exact Test for Count Data

```
data: m
p-value = 0.2416
alternative hypothesis: true odds ratio is greater than 1
95 percent confidence interval:
 0.5753718      Inf
sample estimates:
odds ratio
 1.808415
```

P-Wert

Einseitiges 95%-Vertrauensintervall  
für Odds-ratio

Odds-ratio

R verwendet spezielle numerische Methoden um das Odds ratio zu bestimmen;  
es kann daher leichte Unstimmigkeiten zur Berechnung von Hand geben



# Statistische Tests für Tabellen

- **Fisher's Exact Test:** 2 x 2 Tabellen  
Verteilung der Teststatistik exakt
- **Chi-Quadrat Test:** m x n Tabellen  
Verteilung der Teststatistik **asymptotisch**
- **Logistische Regression:** 2 x m Tabellen;  
auch Mix aus mehreren kontinuierlichen und kategoriellen erklärenden Variablen möglich  
Verteilung der Teststatistik **asymptotisch**  
***Multiple oder einfache ?***


# Chi-Quadrat Test: Spalten und Zeilen unabhängig?

- Haar- und Augenfarbe (R: ?HairEyeColor)

Hair / Eye	Brown	Blue	Hazel	Green	Total
Black	68	20	15	5	108
Brown	119	84	54	29	286
Red	26	17	14	14	71
Blond	7	94	10	16	127
Total	220	215	93	64	592

- Mögliche Fragen:
  - Visualisierung (v.a. wenn mehr als 2 Kategorien)
  - Abhängigkeit? Wo?

# Visualisierung kategorischer Daten: Mosaic Plot



Hair / Eye	Brown	Blue	Hazel	Green	Total
Black	68	20	15	5	108
Brown	119	84	54	29	286
Red	26	17	14	14	71
Blond	7	94	10	16	127

Fläche proportional  
zu Tabelleneintrag

# Chi-Quadrat Test

“observed values”

$$O_{ij} = N_{ij}$$

	A=1	...	A=n	Total
B=1	$N_{11}$		$N_{1n}$	$N_{1*}$
...				
B=m	$N_{m1}$		$N_{mn}$	$N_{m*}$
Total	$N_{*1}$		$N_{*n}$	$N$

$H_0$ : A, B sind unabhängig

$$P(A = i \cap B = j) = P(A = i) * P(B = j) \approx \hat{P}(A = i) * \hat{P}(B = j) = \frac{N_{*i}}{N} * \frac{N_{j*}}{N}$$

Erwartungswert der Zelle falls  $H_0$  stimmt:  $E_{ij} = N * \frac{N_{*i}}{N} * \frac{N_{j*}}{N} = \frac{N_{*i} N_{j*}}{N}$

# Chi-Quadrat Test

	A=1	...	A=n	Total
B=1	$N_{11}$		$N_{1n}$	$N_{1*}$
...				
B=m	$N_{m1}$		$N_{mn}$	$N_{m*}$
Total	$N_{*1}$		$N_{*n}$	$N$

Wie verschieden sind beobachtete und erwartete Werte?

Verbreitet: **Pearson Chi-Quadrat Statistik**

$$X^2 = \sum_{i=1}^n \sum_{j=1}^m \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^n \sum_{j=1}^m R_{ij}^2$$

**Pearson Residuen**

$$R_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

Beitrag jeder Zelle  
zur Modellabweichung

Falls  $H_0$  stimmt, folgt  $X^2$  einer


**Chi-Quadrat Verteilung mit  $(n-1)(m-1)$  Freiheitsgraden**

(falls  $N$  gross – s. nächste slide).

→ p-Werte

# Chi-Quadrat Test: Wann ist Approximation gut ?

- Faustregel:



$E_{ij} < 1$  für mind. ein Tabellenfeld → ungenügend

$E_{ij} > 1$  für alle Tabellenfelder  $i, j$  → gerade noch OK

$E_{ij} > 5$  für alle Tabellenfelder  $i, j$  → sehr gut

- Falls Faustregel nicht erfüllt:

- Kategorien zusammenfassen
- anderen Test verwenden (z.B. Fisher-Test mit Simulation)



# Chi-Quadrat Test in R

```
> chisq.test(tab)
```

Pearson's Chi-squared test

data: tab

X-squared = 138.2898, df = 9, p-value < 2.2e-16

$1 - pchisq(q = 138.2898, df = 9)$


$$\sum_{i=1}^n \sum_{j=1}^m R_{ij}^2$$

$$(4 - 1) * (4 - 1) = 9$$



# Mosaic plot mit Shading: Integrierter Chi-Quadrat Test


Sehr grosser  
Tabelleneintrag



Sehr kleiner  
Tabelleneintrag

Farbe falls  
Pearson Residuen  
ausserhalb  $[-2, 2]$

Pearson  
residuals:



p-value =  
< 2.22e-16

p-Wert des  
Chi-Quadrat  
Tests



# Statistische Tests für Tabellen



- **Fisher's Exact Test:** 2 x 2 Tabellen  
Verteilung der Teststatistik exakt
- **Chi-Quadrat Test:** m x n Tabellen  
Verteilung der Teststatistik asymptotisch
- **Logistische Regression:** 2 x m Tabellen;  
auch Mix aus mehreren kontinuierlichen und kategoriellen erklärenden Variablen möglich  
Verteilung der Teststatistik **asymptotisch**  
***Multiple oder einfache ?***

# Logistische Regression

- $Y \sim \text{Bin}(n, p(x))$

$$\log\left(\frac{p(x)}{1 - p(x)}\right) = \beta_0 + \beta_1 x$$

- Bsp: Dosis 0, 1, 2, ..., 9, 10; je 30 kranke Tiere  
Y: Anzahl genesener Tiere



```
glm(cbind(y, n-y) ~ dosis, data = dat, family = binomial)
```

Dosis=0 → log-odds =  $\beta_0 = -4.29$

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	-4.29356	0.46067	-9.320	<2e-16
dosis	0.74103	0.07601	9.749	<2e-16

Wenn man Dosis um eine Einheit erhöht,  
erhöhen sich die log-odds um  $\beta_1 = 0.74$   
95%-VI:  $0.74 \pm 2 \cdot 0.076$

# Logistische Regression: Interpretation

- Wenn man Dosis um eine Einheit erhöht, erhöhen sich die log-odds um  $\beta_1 = 0.74$   
95%-VI:  $0.74 \pm 2 \cdot 0.076$ , d.h.  $[0.588; 0.892]$

oder äquivalent

- Wenn man Dosis um eine Einheit erhöht, erhöhen sich die odds um den Faktor  $\exp(\beta_1) = 2.10$  (odds-ratio)  
95%-VI:  $[\exp(0.588); \exp(0.892)] = [1.80; 2.44]$

# Einfache oder Multiple Regression

(Gilt für alle GLMs; hier am Bsp der linearen Regression)

- Einfache Regression:  
“Totaler Effekt”  
 $y \sim x \rightarrow$  “Wenn sich  $x$  um eine Einheit erhöht, erhöht sich  $y$  um  $\beta_1$ ”
- Multiple Regression  
“Bereinigter Effekt”  
 $y \sim x_1 + x_2 \rightarrow$  “Wenn sich  $x_1$  um eine Einheit erhöht **und**  $x_2$  **konstant bleibt**, erhöht sich  $y$  um  $\beta_1$ .”
- Kein “richtig” oder “falsch”; eher zwei verschiedene Sichtweisen auf das gleiche Problem

# Vorteil von Multipler Regression

- Andere Einflüsse werden ausgeschaltet, d.h., bereinigter Effekt ist möglich

Bsp: Diskriminierung

- Einfache Regression:  
Zulassung ~ Geschlecht
- Multiple Regression:  
Zulassung ~ Geschlecht + Qualifikation

Berühmtes Beispiel: Simpson's Paradox

# Simpson's Paradox

(Bsp: Aufgenommene Studenten an der UC Berkeley in 1973; nur 6 grösste Departemente)

	Angenommen	Abgelehnt
Männer	1198	1493
Frauen	557	1278

Werden Frauen benachteiligt?



# Methodenvergleich

- Fisher Test
- Chi-Quadrat Test (mit Mosaikplot)
- (einfache) Logistische Regression

```
> head(dfUCB)
```

	Admit	Gender	Dept	Freq
1	Admitted	Male	A	512
2	Rejected	Male	A	313
3	Admitted	Female	A	89
4	Rejected	Female	A	19
5	Admitted	Male	B	353
6	Rejected	Male	B	207
			...	

```
> fm1 <- glm(Admit ~ Gender, weights = Freq, family = binomial, data = dfUCB)
> summary(fm1)
```

Call:  
glm(formula = Admit ~ Gender, family = binomial, data = dfUCB, weights = Freq)

Deviance Residuals:

	Min	1Q	Median	3Q	Max
	-28.787	-14.662	-1.781	15.244	20.336

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	0.22013	0.03879	5.675	1.38e-08 ***
GenderFemale	0.61035	0.06389	9.553	< 2e-16 ***

```
> exp(confint(fm1))
waiting for profiling to be done...
                2.5 %    97.5 %
(Intercept)  1.155124  1.344836
GenderFemale  1.624956  2.087499
```

Frauen benachteiligt ?

# Simpson's Paradox

(Bsp: Aufgenommene Studenten an der UC Berkeley in 1973)

Dept	Männer		Frauen	
	Bew.	Akz.	Bew.	Akz.
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	6%	341	7%



# Simpson's Paradox

(Bsp: Aufgenommene Studenten an der UC Berkeley in 1973)

Dept	Männer		Frauen	
	Bew.	Akz.	Bew.	Akz.
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	6%	341	7%

# Simpson's Paradox

(Bsp: Aufgenommene Studenten an der UC Berkeley in 1973)

Dept	Männer		Frauen	
	Bew.	Akz.	Bew.	Akz.
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	6%	341	7%

Nein: Frauen bewerben sich mehr bei „schwierigen“ Departments!



# Bereinigter Effekt: Logistische Regression

```
glm(formula = Admit ~ Gender + Dept, family = binomial, data = dfUCB,  
     weights = Freq)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	-0.58205	0.06899	-8.436	<2e-16
GenderFemale	-0.09987	0.08085	-1.235	0.217
DeptB	0.04340	0.10984	0.395	0.693
DeptC	1.26260	0.10663	11.841	<2e-16
DeptD	1.29461	0.10582	12.234	<2e-16
DeptE	1.73931	0.12611	13.792	<2e-16
DeptF	3.30648	0.16998	19.452	<2e-16

Der bereinigte Geschlechtereffekt ist nicht signifikant

# Zusammenfassung: Statistische Tests für Tabellen

- **Fisher's Exact Test:** 2 x 2 Tabellen  
Verteilung der Teststatistik **exakt**
- **Chi-Quadrat Test:** m x n Tabellen  
Verteilung der Teststatistik **asymptotisch**
- **Logistische Regression:** 2 x m Tabellen;  
auch Mix aus mehreren kontinuierlichen und kategoriellen erklärenden Variablen möglich  
Verteilung der Teststatistik **asymptotisch**  
***Multiple oder einfache ?***